

◆ 2014 - 2023

Research Interests

*/ computer vision  
/ medical image  
/ generative model  
/ anomaly detection*

# PORTFOLIO

*by* Euyoung Kim

PHONE 010.3362.4772

Github <https://github.com/shreka116>

E-Mail [shreka116@gmail.com](mailto:shreka116@gmail.com)

# CONTENTS

p 03

*Research*

- Chest X-ray Generation with Anatomical Priors (JBHI submission 2023)
- Chest X-ray Generation via Disentangled Contrastive Learning (MEDIMA submission 2023)

p 14

*Projects*

- Product Detect Generation (2022~ )

# RESEARCH

*"Generative Model for Improved Abnormality Detection"*

①

RESEARCH 01 Chest X-ray Generation *with* Anatomical Priors

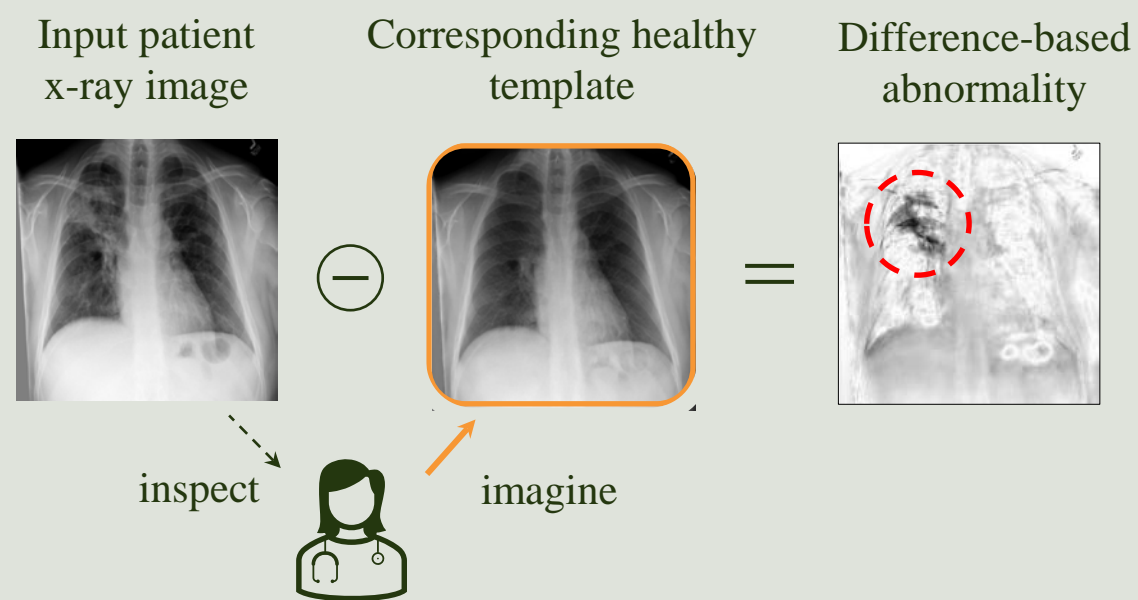
RESEARCH 02 Chest X-ray Generation *via* Disentangled Contrastive Learning

@ 2014 - 2023

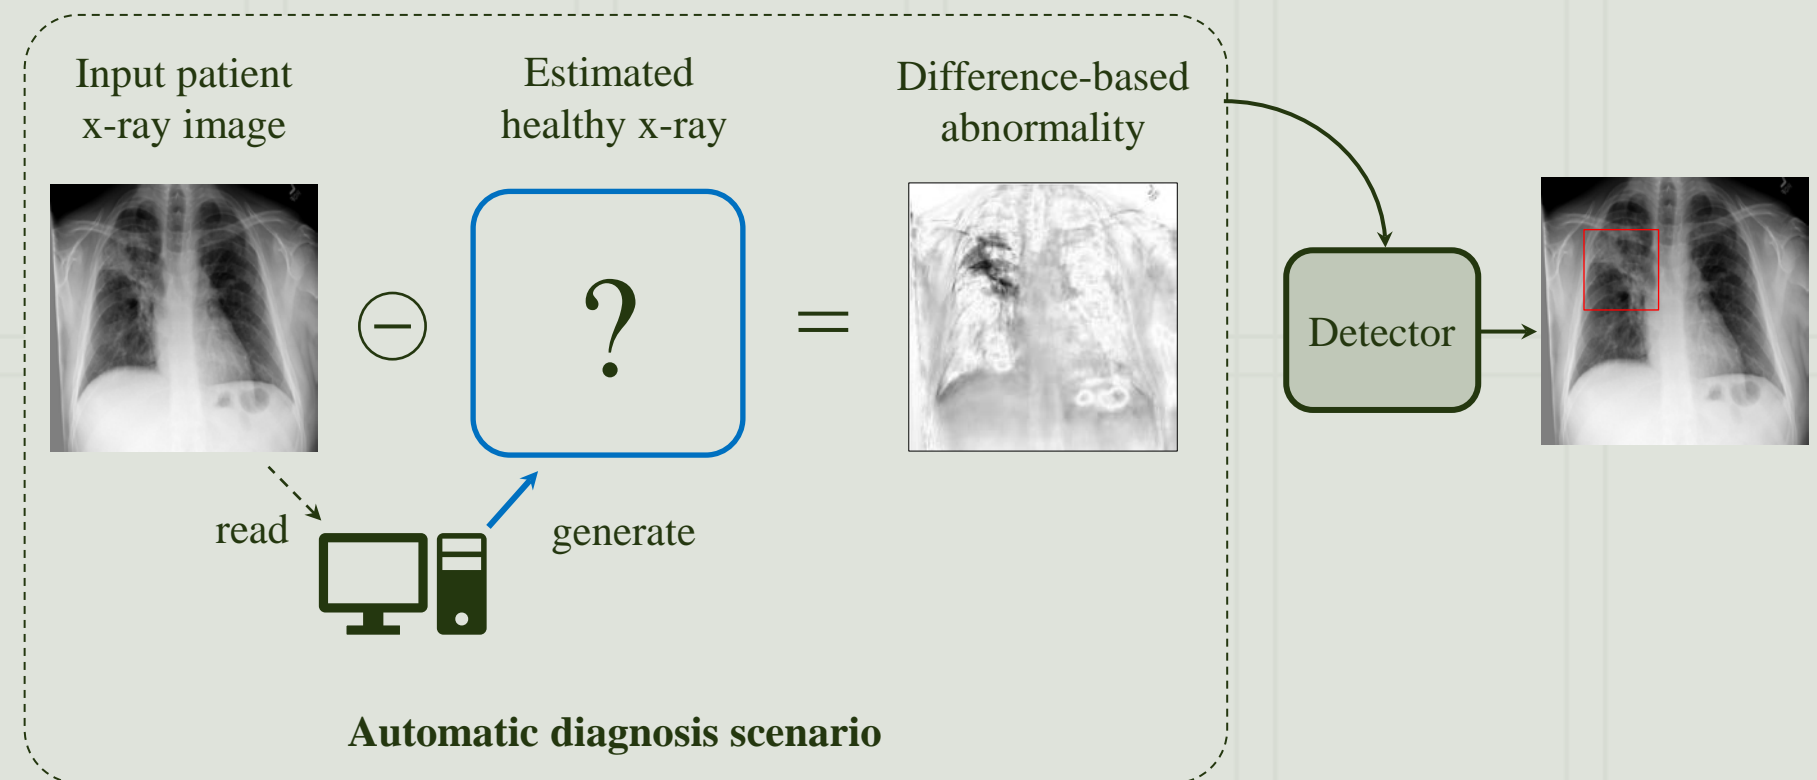
BY Euyoung Kim

# MOTIVATION

"Generative Model for Normal Synthesis"




Hypothesis on "How would a radiologist diagnose?"



- 이상탐지 성능 개선을 위해 의사 또는 임상이가 영상을 보고 진단을 내리는 과정을 모방하는 방법론 제안
  - 의사가 영상 속 병변을 찾기 위해 **질병이 없는 영상을 상상하며** 현재 보고 있는 **영상과의 차를 구해 병변을 시각화**
- 이를 위해 **생성모델**을 활용하여 의사들의 판단이 되는 basis 영상인 normal 영상을 생성하고 이를 **detection** 과 **결합**하는 방법으로 질병 검출 성능 개선

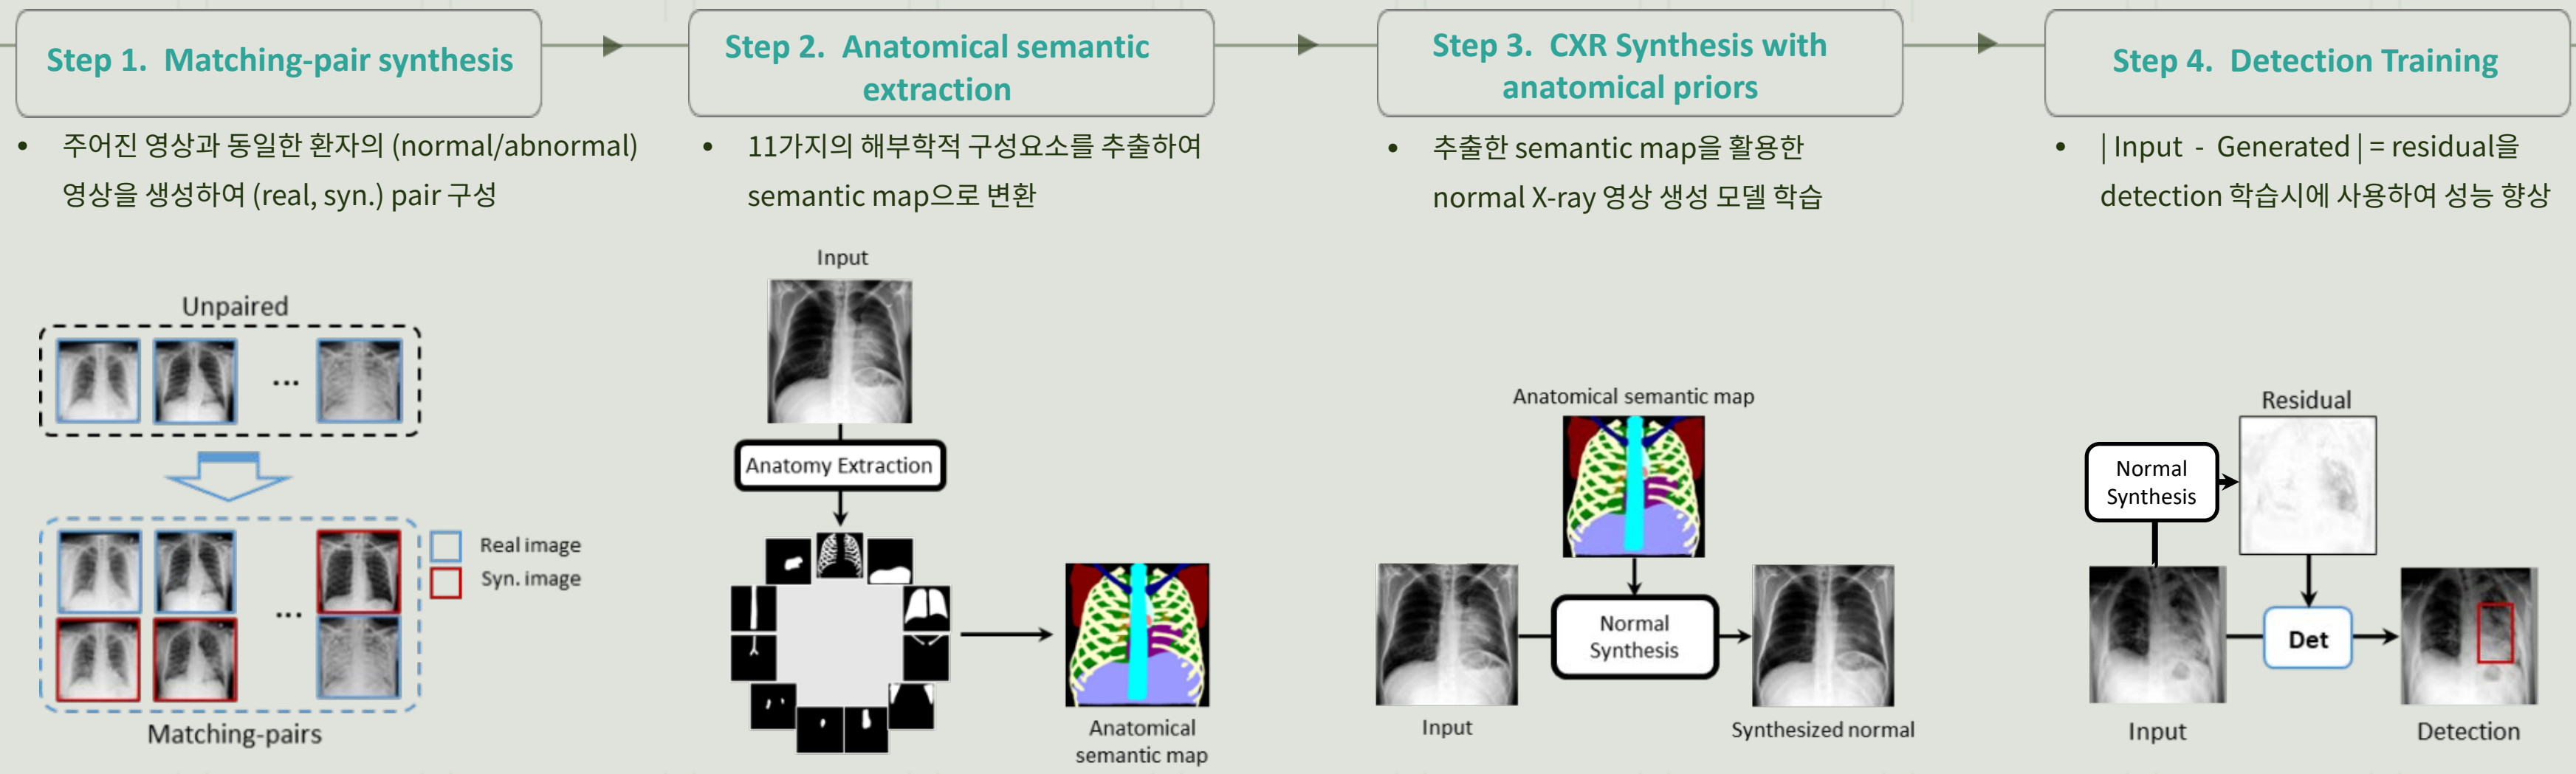
# Chest X-ray Generation *with* Anatomical Priors



**Anatomical prior** 는 “인간의 해부학적 구조는 질병과 무관하게 동일한 사람에 대해서는 균일하다” 라는 성질을 이용하는 해부학적 prior knowledge를 뜻합니다. 본 연구에서는 해부학적 정보를 활용한 CXR generation을 제안합니다.


제안 방법은 총 4단계로 구성됩니다.

- 1) Unpaired 영상을 사용한 matching-pair synthesis
- 2) Anatomical semantic map extraction
- 3) Normal X-ray synthesis with anatomical priors
- 4) 학습된 normal X-ray synthesis 결과를 detection에 결합하여 이상 검출 성능 개선





# CXR Generation

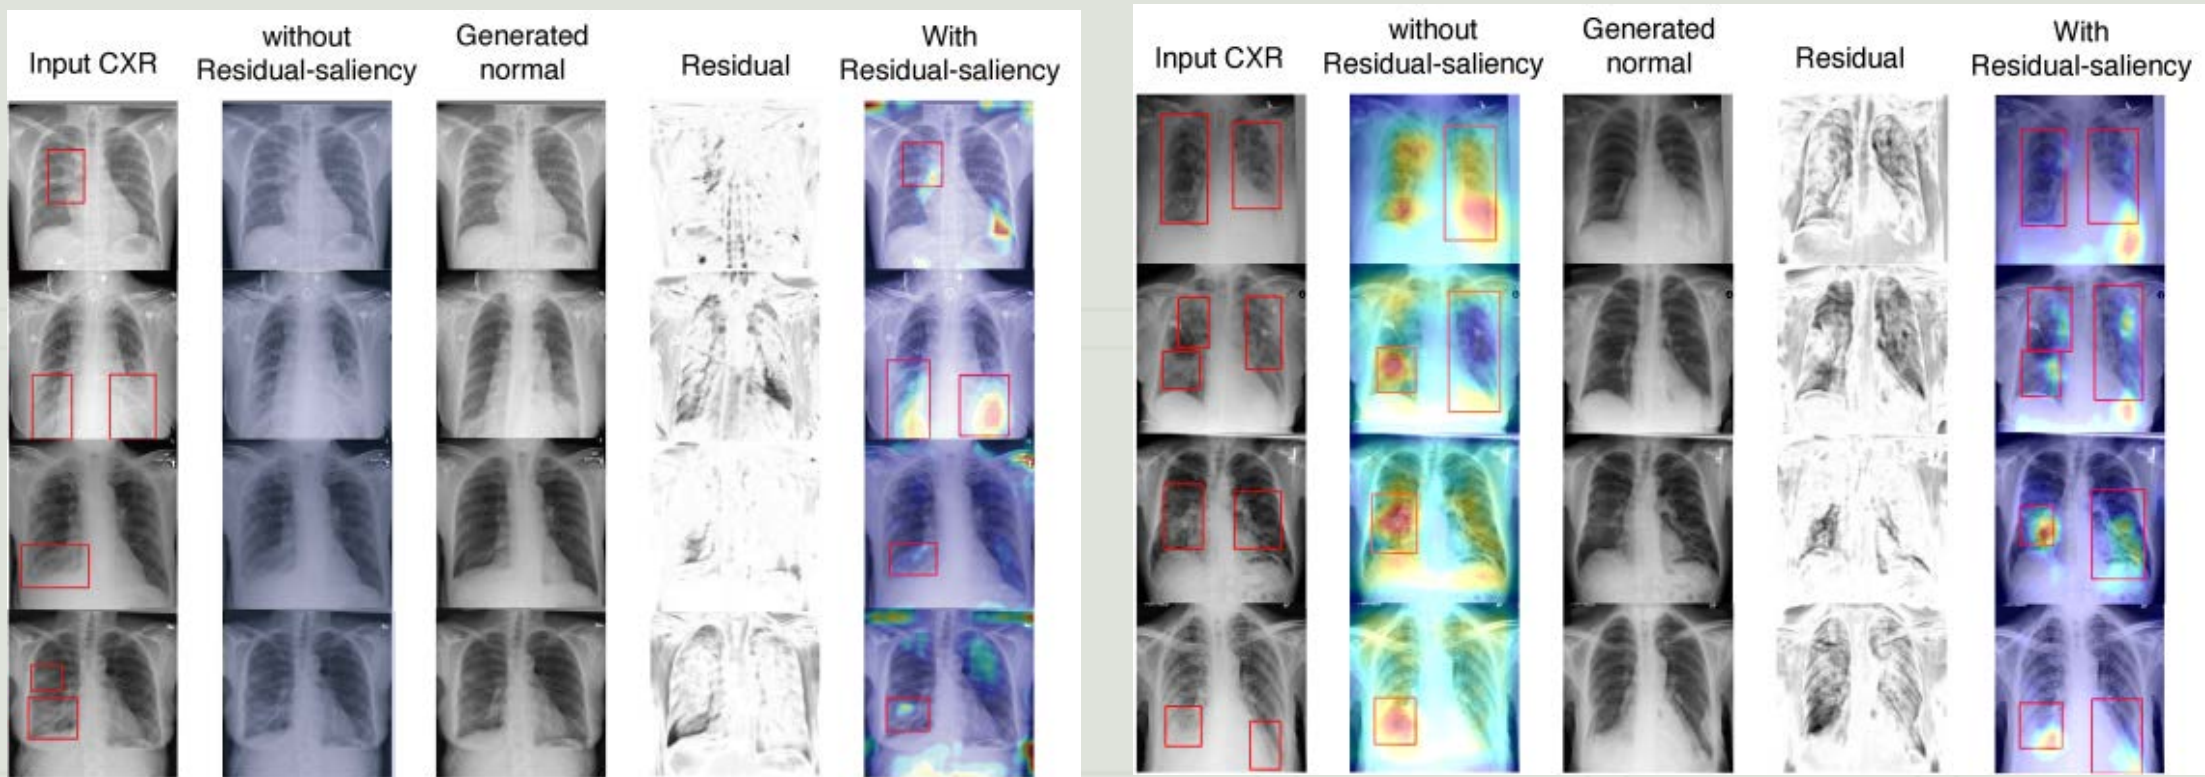


- 제안한 해부학적 정보를 활용시 입력 영상과 더욱 해부학적으로 일치하는 영상을 생성함과 동시에 다른 생성기법들에 비해 입력 abnormal 영상에서 질병에 연관된 영역만을 지우는 것을 확인
- 반면, 다른 기법들은 갈비뼈의 디테일을 살리지 못하거나 심장 또는 횡격막의 모양이 유지되지 않음



# Improved Detection

Effects of "residual-saliency" on detection accuracy



- 병변에 대한 정보가 내포되어있는 residual map을 활용하여 이전에 놓쳤던 질병들을 성공적으로 다시 찾아내 성능을 개선
- Synthetic abnormal X-ray를 학습데이터와 함께 사용시 (data augmentation) 추가적 성능 개선을 확인


RSNA pneumonia dataset

Method	mAP	AP <sub>0.4</sub>	AP <sub>0.5</sub>	AP <sub>0.6</sub>
GeminiNet [50]	0.2961	0.4584	0.3808	0.2845
RetinaNet [54]	0.1927	0.3824	0.2915	0.1927
RetinaNet* [23]	0.3962	0.6234	0.5142	0.3782
+ CycleGAN [2]	0.3961	0.6279	0.5200	0.3727
+ MUNIT [3]	0.3959	0.6251	0.5174	0.3770
+ DGM [4]	0.3950	0.6239	0.5144	0.3680
RSAD [5]	0.3988	0.6313	0.4797	0.3815
+ (syn.)	0.4228	0.6293	0.5373	0.4067
TargetedGAN	0.4006	0.6169	0.5152	0.3883
+ (syn.)	0.4191	0.6416	0.5394	0.4017
RetinaNet* [23]				
+ AntGAN (ours, <i>concat.</i> )	0.3975	0.6236	0.5211	0.3770
+ AntGAN (ours, <i>attention</i> )	0.4116	0.6364	0.5434	0.3995
+ AntGAN (ours, <i>attention, syn.</i> )	0.4459	0.6476	0.5584	0.4316
* Modified RetinaNet				



# Chest X-ray Generation via

## Disentangled Contrastive Learning



“인간의 해부학적 구조는 질병과 무관하게 동일한 사람에 대해서는 균일하다”라는 성질을 이용하여 X-ray 영상 내 속성을 **개인별(person-specific)** 및 **질병별(disease-specific)** 속성으로 분리하여 생성모델을 학습하여 효과적으로 가상환자의 이미지를 생성하고 질병의 유무 또한 control 할 수 있는 생성모델을 제안합니다.

## RESEARCH 02

### Contrastive Learning

- 주어진 X-ray 영상을 contrastive learning을 통해 person- 과 disease-specific 정보로 disentangle
- 매칭패어를 포함한 모든 영상들 간의 relation 정의
  - D-pair : disease-attribute relations between images
  - P-pair : person-attribute relations between images

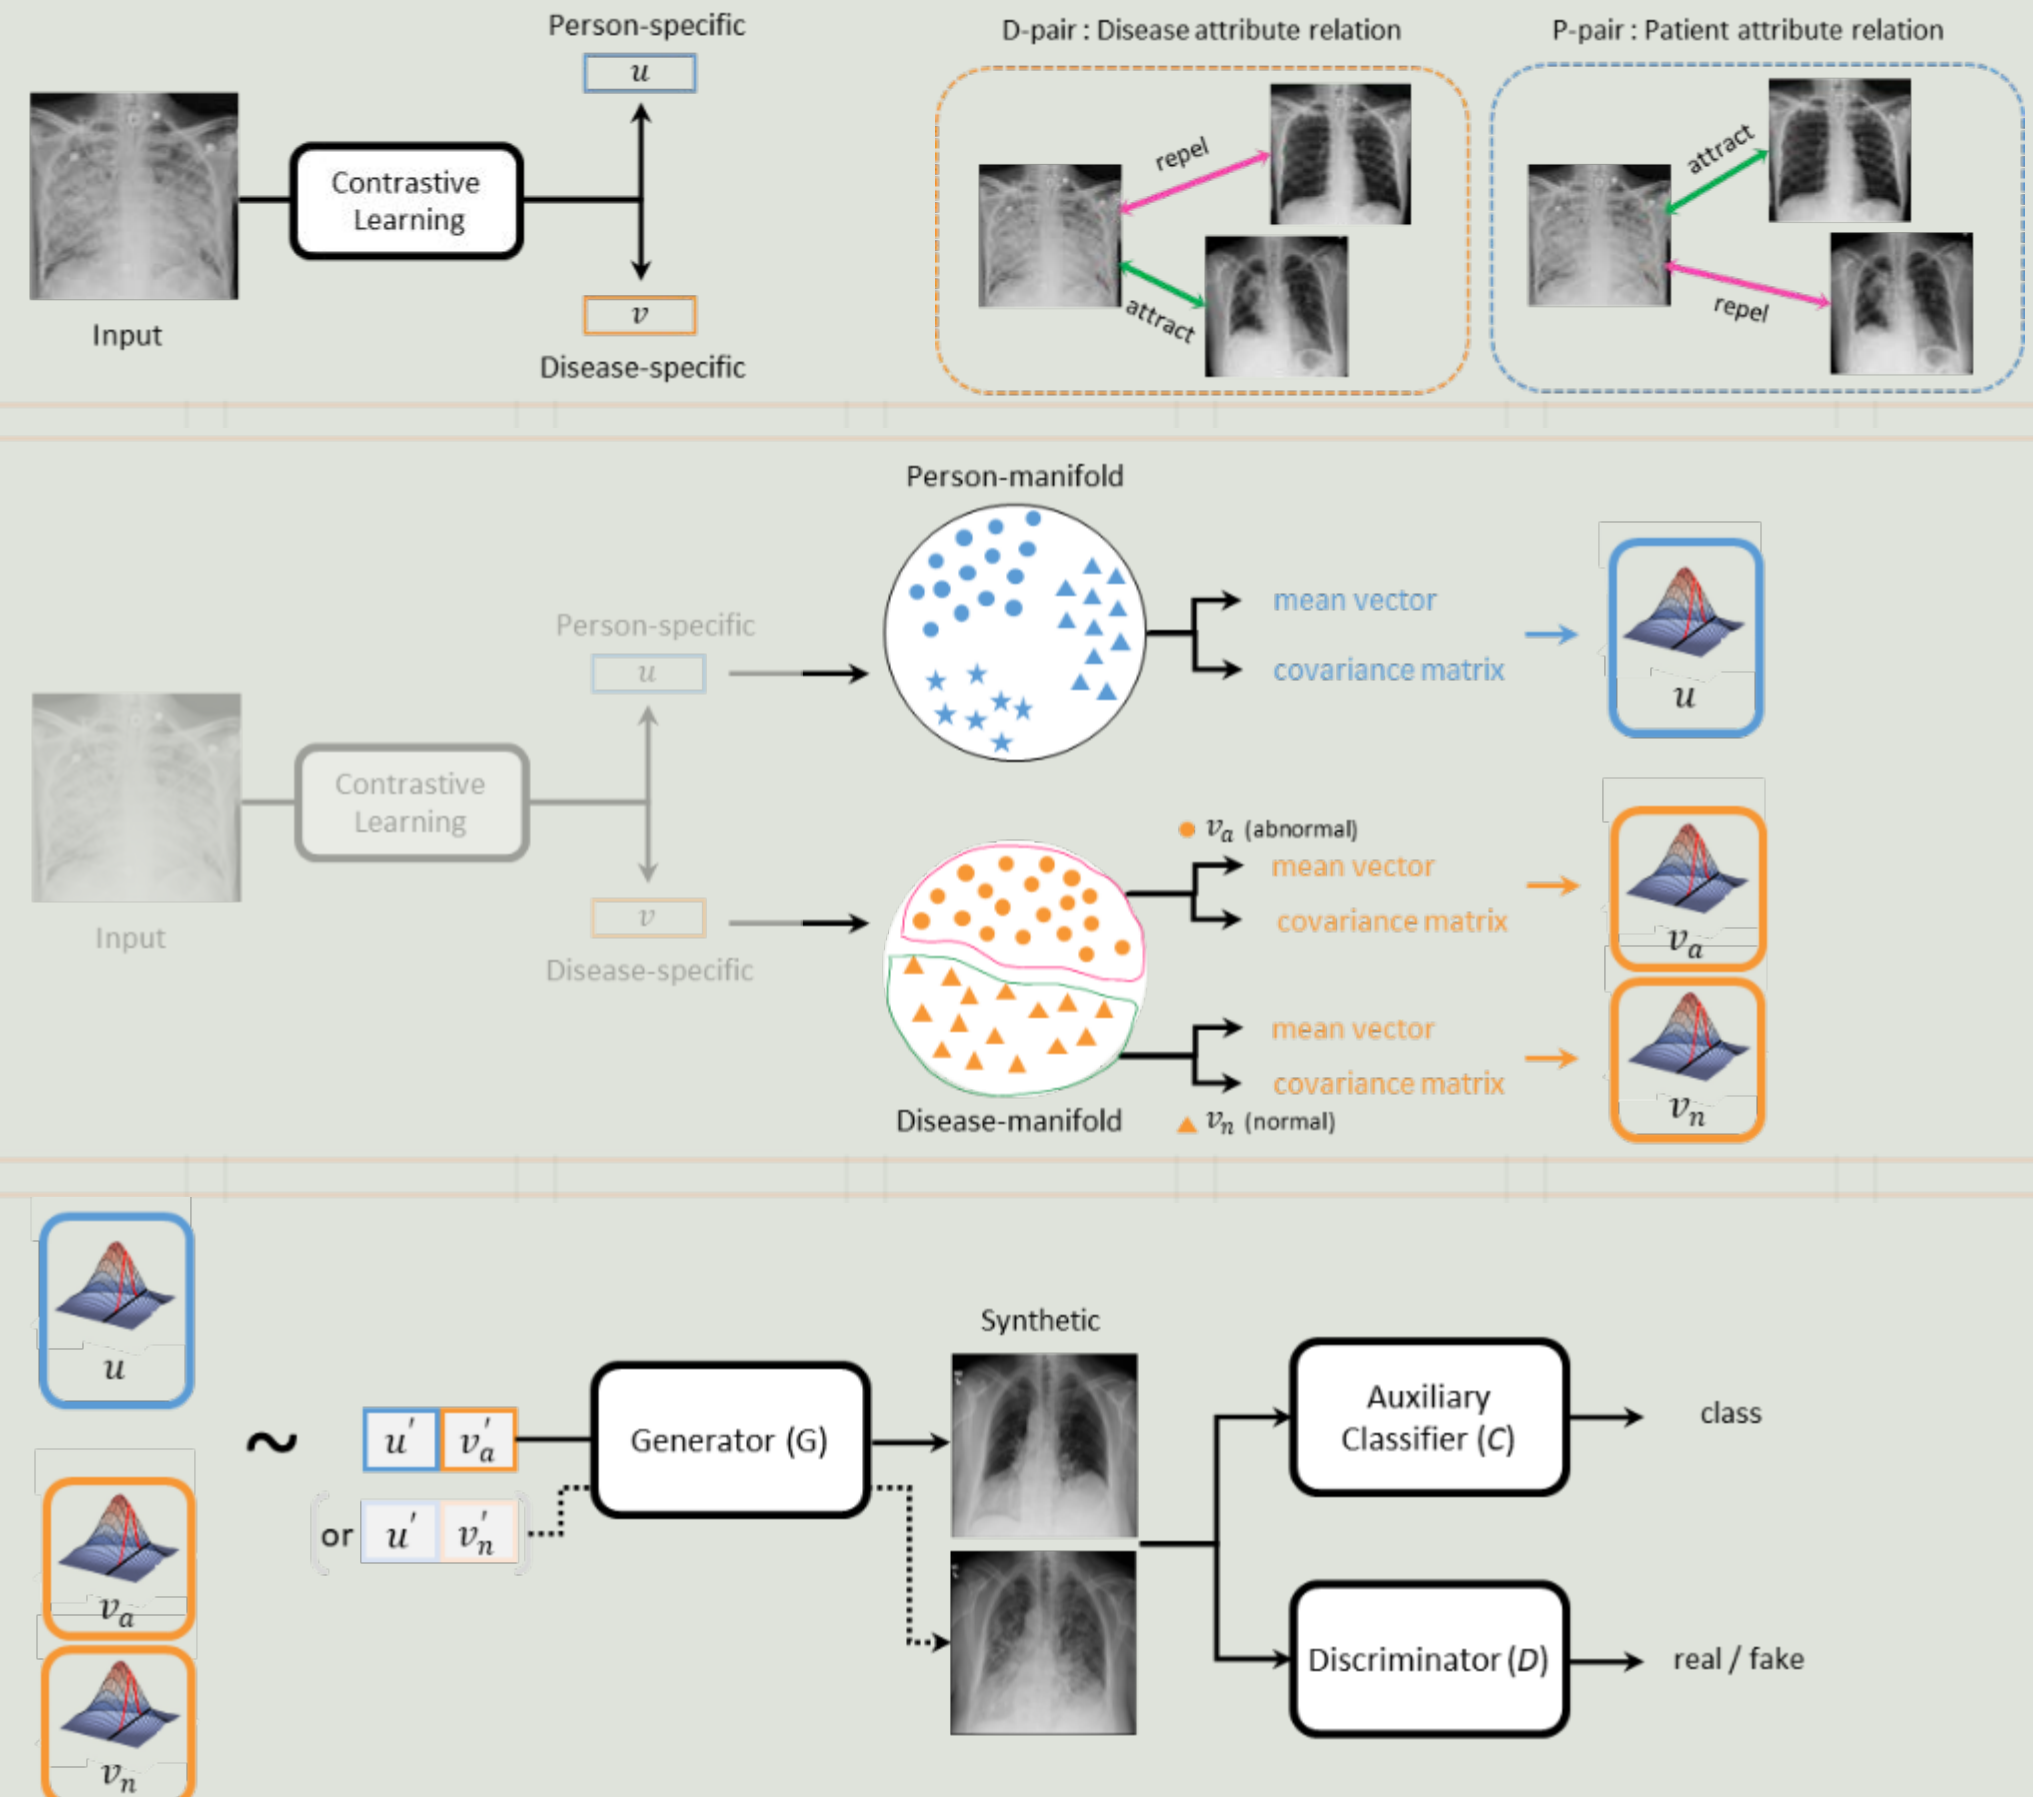
### Distribution Modeling

- 모든 X-ray 영상들의 person- 과 disease-specific vector 추출
  - For each attribute, compute mean vector covariance matrix
- Multivariate Gaussian modeling
  - Person-specific attribute gaussian
  - Disease-specific attribute gaussian
    - Abnormal attribute
    - Normal attribute

### Disentangled Generation

- 앞서 modeling한 각 attribute에 대한 multivariate Gaussian 분포에서부터 latent code를 random sampling 해서 generation model 학습
- Auxiliary classification module을 추가하여 생성영상과 sampled latent code의 label이 일치 되도록 constraint 부여

## CXR Generation via Disentangled Contrastive Learning






# CXR Generation



Synthesized Abnormal CXRs




Synthesized Normal CXRs



Synthesized CXRs across different key attributes

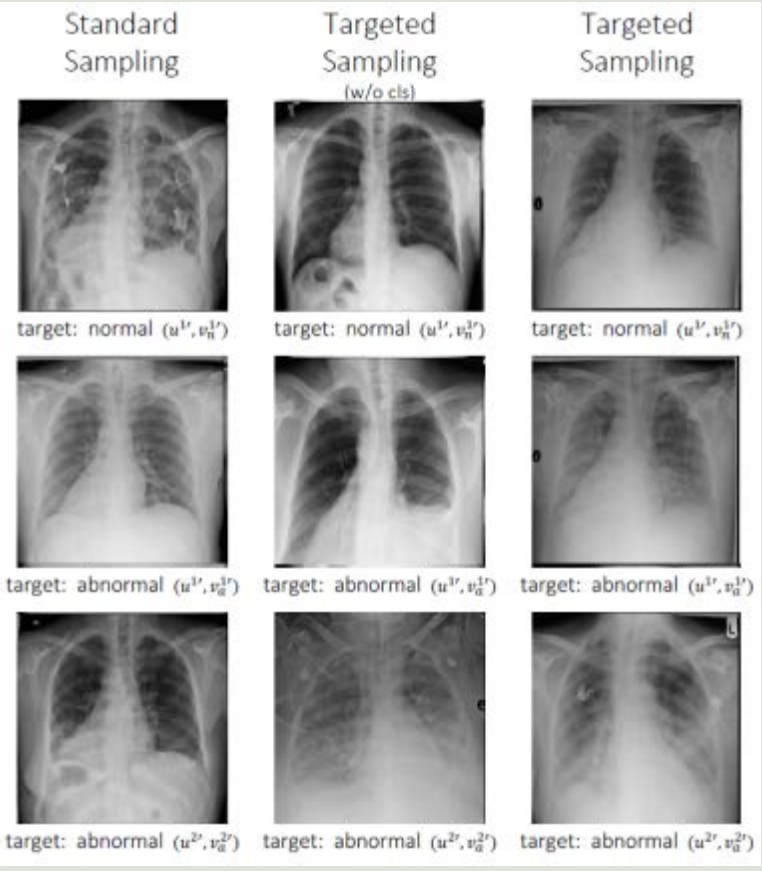
# CXR Generation

Disentangled generation comparisons



- Abnormal-to-normal translation의 경우 모든 기법이 잘 동작
- 하지만, normal-to-abnormal translation의 경우 기존 기법들은 localized 영역이 아닌 global contrast를 변경하는 등 아쉬운 성능을 보이는 반면, 제안한 기법은 성공적으로 abnormal 영상 생성

Effect of auxiliary classifier




- Classifier를 함께 사용시 원하는 특정 클래스의 영상 생성 가능



# CXR Generation

## Task 1. Distinguish reals from given paired CXR

Q1. 아래 쌍의 X-ray 영상 중 진품에 해당하는 영상을 선택하십시오.



☐ Left (pneumonia)

☐ Right (non-pneumonia)

## Task 2. Distinguish reals from fakes

Q3. 아래 X-ray 영상의 진위여부를 판단하십시오.



☐ 진품 (real)

☐ 가품 (synthetic)

Expert evaluation

Type	acc.	prec.	sp.	se.
Task 1	0.90	0.90	0.90	0.90
Task 2	0.68	0.67	0.70	0.66

### 방사선 전문의 다섯분을 모셔서 총 두가지 survey 진행

Task 1 : 20개의 matching-pair들을 하나의 pair씩 보여주며, 그 중에 진짜 X-ray 영상이 무엇인지를 구별하는 것이 목적

Task 2 : 랜덤하게 샘플링한 생성 영상과 진짜 영상을 각 10장씩 총 20장의 X-ray 영상 중 진짜 영상을 찾는 것이 목적

- 첫번째 실험에서는 대 다수의 전문의들이 진짜 영상을 찾아낼 수 있음을 확인
- 두번째 실험에서는 진짜 영상을 찾는 빈도수가 현저히 줄어들었음을 확인  
>> 제안하는 기법의 생성모델이 진짜 영상과 유사한 X-ray 영상들을 생성함

# PROJECTS

PROJECT 01    Product Detect Generation


@ 2022 - present

BY    Euyoung Kim

PROJECT 01

Collaboration with Cognex  
**Product Defect Generation**

기간 2022 . 01 ~ present  
작업 Defect Generation Model 개발  
참여도 개인 (100%)



- ▼ **Challenge**

실제 산업현장의 경우 다음과 같은 이유로 인한 supervised 방식의 defect segmentation 학습에 어려움 발생

  - 1) 학습데이터 imbalance 문제 (양품대비 불량 샘플의 현저한 부족)
  - 2) 충분한 양의 라벨링된 학습데이터 확보 어려움
- ▼ **Objective**

본 프로젝트에서는 실제 영상과 매우 유사한 defect 영상 및 defect mask를 동시에 생성하는 생성모델을 설계하여 학습데이터 imbalance 문제 및 데이터 부족 문제를 풀고자 함

## PROJECT 01

### Challenge 1

- 학습데이터 imbalance 문제 (양품대비 불량 샘플의 현저한 부족)


### Solution

Denoising Diffusion Probabilistic Model (DDPM) 을 활용하여 defect 영상 생성 모델을 설계하였으며, 제안한 defect 영상 생성 모델은 다음과 같은 step으로 이루어져있습니다.

- 1) defect mask manifold를 DDPM을 활용하여 학습
- 2) synthetic defect mask와 양품의 정상 영상을 함께 blending하여 최종적으로 defect 영상 생성

### Results

진품 영상의 비율이 현저히 낮은 상황에서 추가적인 생성 영상 활용시 최대 +37% 성능 향상




Generated defect mask

Real normal


Overlaid

Blended

#### 1) Learning "defect mask manifold"



#### 2) Blending "synthetic defect masks" with "real normal" samples → synthetic defects





## PROJECT 01

### Challenge 2

- 충분한 양의 라벨링된 학습데이터 확보 어려움


### Solution

Denoising Diffusion Probabilistic Model (DDPM) 을 활용하여 적은 defect 영상을 가지고도 defect 생성이 가능한 생성 모델을 설계하였으며, 제안한 생성 모델은 다음과 같은 step으로 이루어져있습니다.


- 1) normal manifold를 DDPM을 활용하여 학습
- 2) 제한된 양의 defect 영상을 condition으로 학습되어지는 ‘conditioning encoder’ 학습

### Results


제한된 양의 defect 영상을 가지고도 진짜와 유사한 defect 영상 생성 가능 ( in progress ... )



Input defect mask



generated defect




Input defect mask




generated defect

### 1) Learning “normal manifold”



### 2) Training “conditioning encoder” for defect synthesis



**Thank you for enjoying**

AI Researcher Portfolio  
by Euyoung Kim

PHONE 010.3362.4772

Github [github.com/shreka116](https://github.com/shreka116)

E-Mail [shreka116@gmail.com](mailto:shreka116@gmail.com)